

Perbandingan Performa Algoritma Decision Tree, Naïve Bayes, dan K-Nearest Neighbors Menggunakan F1-Score untuk Klasifikasi Tingkat Stres Mahasiswa

Elfin Ridha Kresno¹, Naura Zulfa Azizah², Elberth Natan Pratama Limbong³

Stres merupakan salah satu permasalahan kesehatan mental yang dapat memengaruhi kondisi psikologis dan produktivitas mahasiswa. Identifikasi tingkat stres diperlukan untuk memahami pola faktor yang berhubungan dengan kondisi tersebut secara lebih objektif. Penelitian ini bertujuan membandingkan performa algoritma Decision Tree, Naïve Bayes, dan K-Nearest Neighbors (KNN) dalam melakukan klasifikasi tingkat stres mahasiswa menggunakan dataset Student Stress Factors: A Comprehensive Analysis. Tahapan penelitian meliputi preprocessing data, seleksi fitur menggunakan korelasi Pearson dengan memilih sebanyak 17 fitur yang memiliki hubungan kuat terhadap variabel target stress_level, optimasi parameter menggunakan GridSearchCV, serta evaluasi model menggunakan Stratified K-Fold Cross Validation. Performa algoritma dievaluasi menggunakan metrik precision, recall, dan F1-Macro sebagai metrik utama perbandingan. Hasil eksperimen menunjukkan bahwa ketiga algoritma mampu melakukan klasifikasi tingkat stres mahasiswa dengan performa yang kompetitif. Berdasarkan nilai F1-Macro, Naïve Bayes memperoleh nilai tertinggi sebesar 88,47%, diikuti oleh Decision Tree sebesar 87,72% dan K-Nearest Neighbors sebesar 86,73% pada dataset yang digunakan dalam penelitian ini.

Keywords: Machine Learning, Stress Classification, Decision Tree, Naïve Bayes, K-Nearest Neighbors, Pearson Correlation.

I. INTRODUCTION

1. Latar Belakang

Stres merupakan salah satu permasalahan psikologis yang dapat memengaruhi kesehatan mental, kondisi fisik, serta produktivitas individu. Menurut *World Health Organization* (WHO), kesehatan mental dipengaruhi oleh berbagai faktor individu, sosial, dan lingkungan yang saling berhubungan sehingga diperlukan perhatian terhadap faktor-faktor yang dapat memengaruhinya [1]. Selain itu, penelitian menunjukkan bahwa berbagai tekanan yang berasal dari aspek akademik, sosial, maupun personal dapat menjadi faktor yang berkontribusi terhadap meningkatnya kondisi stres pada individu [2]. Kondisi tersebut menunjukkan bahwa diperlukan pendekatan yang mampu mengidentifikasi pola faktor-faktor yang berhubungan dengan tingkat stres secara lebih sistematis, sehingga proses klasifikasi tingkat stres dapat dilakukan secara lebih objektif berdasarkan karakteristik data individu.

Mahasiswa merupakan salah satu kelompok

yang rentan mengalami stres karena menghadapi berbagai tuntutan selama masa perkuliahan. Beban akademik, kondisi psikologis, tekanan pencapaian prestasi, faktor sosial, serta gaya hidup dapat berhubungan dengan tingkat stres yang dialami mahasiswa [2], [3]. Tingkat stres yang tinggi dapat berdampak pada kesehatan mental, kualitas hidup, dan performa akademik mahasiswa. Namun, perbedaan karakteristik data dan pola hubungan antar faktor yang memengaruhi stres dapat menyebabkan setiap algoritma Machine Learning memiliki kemampuan klasifikasi yang berbeda. Oleh karena itu, diperlukan evaluasi terhadap beberapa algoritma klasifikasi untuk mengetahui pendekatan yang mampu memberikan performa terbaik dalam mengidentifikasi tingkat stres mahasiswa.

Perkembangan teknologi *Machine Learning* memberikan peluang dalam melakukan klasifikasi tingkat stres dengan memanfaatkan pola hubungan antar variabel pada dataset. Penelitian ini menggunakan dataset *Student Stress Factors: A Comprehensive Analysis* yang mencakup faktor akademik, psikologis, sosial, fisiologis, dan lingkungan, sehingga diperlukan proses seleksi fitur untuk menentukan atribut yang memiliki hubungan paling relevan terhadap tingkat stres [4]. Untuk memperoleh fitur yang lebih relevan terhadap proses klasifikasi, dilakukan seleksi fitur menggunakan korelasi Pearson dengan memilih variabel yang memiliki nilai korelasi absolut $|r| \geq 0,6$ terhadap variabel target *stress_level*. Pemilihan batas tersebut didasarkan pada interpretasi bahwa nilai korelasi yang semakin mendekati -1 atau 1 menunjukkan hubungan yang semakin kuat antar variabel [5]. Penggunaan nilai absolut dilakukan agar fitur dengan hubungan negatif tetap dipertahankan karena tetap menunjukkan hubungan yang kuat terhadap *stress_level*, meskipun memiliki arah hubungan yang berlawanan. Oleh karena itu, penelitian ini bertujuan untuk membandingkan performa algoritma *Decision Tree*, *Naïve Bayes*, dan *K-Nearest Neighbors* (KNN) dalam melakukan klasifikasi tingkat stres mahasiswa. Perbandingan dilakukan menggunakan beberapa metrik evaluasi klasifikasi dengan F1-Score sebagai

metrik utama untuk menentukan algoritma dengan performa terbaik dalam mengenali pola tingkat stres berdasarkan fitur hasil seleksi korelasi Pearson. Penggunaan F1-Score dipilih karena mampu mempertimbangkan keseimbangan antara precision dan recall dalam proses klasifikasi multi-kelas tingkat stres.

2. Rumusan Masalah

Bagaimana perbandingan performa algoritma *Decision Tree*, *Naïve Bayes*, dan *K-Nearest Neighbors* dalam mengklasifikasikan tingkat stres mahasiswa berdasarkan nilai Macro F1-Score menggunakan fitur hasil seleksi korelasi Pearson?

3. Hipotesis

1. Hipotesis Nol (H_0)

Tidak terdapat perbedaan performa antara algoritma *Decision Tree*, *Naïve Bayes*, dan *K-Nearest Neighbors* berdasarkan nilai Macro F1-Score.

2. Hipotesis Alternatif (H_1)

Terdapat perbedaan performa antara algoritma *Decision Tree*, *Naïve Bayes*, dan *K-Nearest Neighbors* berdasarkan nilai Macro F1-Score.

4. Manfaat Penelitian

1. Manfaat Teoritis

Penelitian ini diharapkan dapat memberikan kontribusi terhadap pengembangan kajian *Machine Learning*, khususnya dalam penerapan dan perbandingan algoritma klasifikasi *Decision Tree*, *Naïve Bayes*, dan *K-Nearest Neighbors* (KNN) untuk mengklasifikasikan tingkat stres mahasiswa berdasarkan evaluasi performa menggunakan Macro F1-Score.

2. Manfaat Praktis

Penelitian ini diharapkan dapat memberikan informasi mengenai algoritma *Machine Learning* yang memiliki performa terbaik dalam melakukan klasifikasi tingkat stres mahasiswa berdasarkan nilai Macro F1-Score. Hasil penelitian ini dapat menjadi referensi dalam pengembangan sistem berbasis *Machine Learning* yang dapat membantu proses identifikasi tingkat stres secara objektif berdasarkan faktor-faktor yang terdapat pada dataset.

5. Batasan Penelitian

Penelitian ini menggunakan dataset *Student Stress Factors: A Comprehensive Analysis* dengan variabel target *stress_level* yang terdiri dari tiga kategori tingkat stres. Variabel independen yang digunakan merupakan fitur yang memiliki nilai korelasi absolut $|r| \geq 0,6$ berdasarkan analisis korelasi Pearson. Penelitian ini membandingkan tiga algoritma klasifikasi, yaitu *Decision Tree*, *Naïve Bayes*, dan *K-Nearest Neighbors* (KNN) dalam melakukan klasifikasi tingkat stres mahasiswa. Evaluasi model dilakukan menggunakan metode *Stratified K-Fold Cross Validation* dan optimasi parameter menggunakan *GridSearchCV*. Performa model dievaluasi menggunakan *accuracy*, *precision*, *recall*,

Macro F1-Score, *confusion matrix*, dan *confidence prediction* dengan *Macro F1-Score* digunakan sebagai metrik utama dalam menentukan algoritma dengan performa terbaik. Penelitian ini tidak membahas penerapan model sebagai alat diagnosis kesehatan mental, tetapi hanya berfokus pada proses klasifikasi berdasarkan data yang tersedia.

II. DATASET AND PREPROCESSING

1. Dataset

Penelitian ini menggunakan dataset *Student Stress Factors: A Comprehensive Analysis* yang diperoleh dari platform Kaggle [4]. Dataset tersebut berisi berbagai faktor yang berkaitan dengan tingkat stres mahasiswa, meliputi aspek psikologis, akademik, sosial, fisiologis, dan lingkungan. Dataset dipilih karena menyediakan data yang relevan untuk mengidentifikasi faktor-faktor yang berhubungan dengan tingkat stres mahasiswa serta dapat digunakan untuk membangun model klasifikasi berbasis *Machine Learning*.

Dataset terdiri dari 1.100 observasi dengan 20 variabel independen dan 1 variabel target, yaitu *stress_level*. Variabel target terbagi menjadi tiga kelas, yaitu rendah (0), sedang (1), dan tinggi (2). Oleh karena itu, penelitian ini termasuk ke dalam permasalahan klasifikasi multikelas (*multiclass classification*) yang bertujuan mengelompokkan data mahasiswa ke dalam salah satu tingkat stres berdasarkan karakteristik yang dimiliki.

Tabel 1. Deskripsi Variabel Penelitian

Variabel	Deskripsi
<i>anxiety_level</i>	Tingkat kecemasan mahasiswa
<i>self_esteem</i>	Tingkat kepercayaan diri mahasiswa
<i>depression</i>	Tingkat depresi mahasiswa
<i>mental_health_history</i>	Riwayat gangguan kesehatan mental
<i>bullying</i>	Pengalaman perundungan
<i>study_load</i>	Beban akademik
<i>future_career_concerns</i>	Kekhawatiran terhadap karier masa depan
<i>extracurricular_activities</i>	Keterlibatan dalam kegiatan non-akademik
<i>peer_pressure</i>	Tekanan dari lingkungan pertemanan
<i>headache</i>	Frekuensi sakit kepala
<i>sleep_quality</i>	Kualitas tidur
<i>noise_level</i>	Tingkat kebisingan lingkungan
<i>living_conditions</i>	Kondisi tempat tinggal
<i>safety</i>	Tingkat rasa aman
<i>basic_needs</i>	Pemenuhan kebutuhan dasar
<i>social_support</i>	Dukungan sosial
<i>teacher_student_relationship</i>	Hubungan mahasiswa dan dosen
<i>stress_level</i>	Target klasifikasi (Tingkat Stres)

Pada penelitian ini tidak seluruh variabel digunakan sebagai fitur masukan model. Seleksi fitur

dilakukan menggunakan korelasi Pearson terhadap variabel target *stress_level*. Variabel dengan nilai korelasi absolut $|r| \geq 0,6$ dipilih karena menunjukkan hubungan yang kuat dengan variabel target. Dan variabel yang terpilih terdapat 17 variabel.

Tabel 2. Fitur Terpilih Berdasarkan Korelasi Pearson

Variabel	Korelasi
<i>Bullying</i>	0.751162
<i>future career concerns</i>	0.742619
<i>anxiety level</i>	0.736795
<i>depression</i>	0.734379
<i>headache</i>	0.713484
<i>extracurricular activities</i>	0.692977
<i>peer pressure</i>	0.690684
<i>noise level</i>	0.663371
<i>mental health history</i>	0.648644
<i>study load</i>	0.634156
<i>social support</i>	-0.632497
<i>teacher_student_relationship</i>	-0.680163
<i>basic needs</i>	-0.708968
<i>safety</i>	-0.709602
<i>academic performance</i>	-0.720922
<i>sleep quality</i>	-0.749068
<i>self esteem</i>	-0.756195


Berdasarkan analisis korelasi Pearson, fitur yang digunakan dalam proses pemodelan merupakan atribut yang memiliki hubungan kuat terhadap variabel target *stress_level* dengan nilai korelasi absolut $|r| \geq 0,6$.

Tabel 3. Statistik Deskriptif Variabel Utama

Variabel	Mean	Median	Std Dev	Min	Max
<i>anxiety level</i>	11.06	11.00	6.12	0	21
<i>self esteem</i>	17.78	19.00	8.94	0	30
<i>depression</i>	12.56	12.00	7.73	0	27
<i>headache</i>	2.51	3.00	1.41	0	5
<i>sleep quality</i>	2.66	2.50	1.55	0	5
<i>study load</i>	2.62	2.00	1.32	0	5
<i>peer pressure</i>	2.73	2.00	1.43	0	5
<i>bullying</i>	2.62	3.00	1.53	0	5
<i>stress_level</i>	1.00	1.00	0.82	0	2

Statistik deskriptif dilakukan untuk memberikan gambaran awal mengenai karakteristik dataset. Hasil analisis menunjukkan bahwa beberapa variabel, seperti *anxiety level*, *depression*, dan *self esteem*, memiliki rentang nilai yang lebih besar dibandingkan variabel lainnya yang umumnya berada pada skala 0 hingga 5. Perbedaan skala tersebut menjadi salah satu alasan dilakukannya normalisasi data sebelum proses pelatihan model.

Gambar 1. Correlation Heatmap




Correlation Heatmap digunakan untuk memvisualisasikan nilai korelasi antar variabel dalam dataset. Visualisasi ini membantu mengidentifikasi fitur yang memiliki hubungan kuat dengan variabel target *stress_level* dan mendukung proses seleksi fitur menggunakan korelasi Pearson.

Gambar 2. Histogram Distribusi Fitur



Histogram digunakan untuk melihat distribusi nilai pada masing-masing fitur sebelum dilakukan proses pemodelan. Visualisasi ini membantu memahami karakteristik data serta mengetahui pola penyebaran setiap variabel.

Gambar 3. Boxplot Distribusi Fitur



Boxplot digunakan untuk mengidentifikasi distribusi data dan kemungkinan adanya outlier pada setiap atribut. Berdasarkan hasil pemeriksaan, data tetap dipertahankan karena tidak ditemukan anomali yang signifikan yang dapat mengganggu proses klasifikasi.

2. Pra-Pemrosesan Data

Pra-pemrosesan data dilakukan untuk meningkatkan kualitas dataset sebelum digunakan dalam proses pelatihan model *Machine Learning*. Tahapan ini meliputi pemeriksaan kualitas data, seleksi fitur, serta standarisasi data agar model dapat mempelajari pola data secara lebih efektif.

1) Data Cleaning

Tahap *data cleaning* dilakukan untuk memastikan kualitas dataset sebelum proses pemodelan. Pemeriksaan meliputi keberadaan *missing value* dan data duplikat. Hasil pemeriksaan menunjukkan bahwa dataset tidak memiliki nilai yang hilang maupun data duplikat sehingga seluruh data dapat digunakan pada tahap berikutnya.

2) Penanganan Missing Value

Berdasarkan hasil pemeriksaan, tidak ditemukan *missing value* pada seluruh atribut dataset. Oleh karena itu, tidak dilakukan proses imputasi maupun penghapusan data dan seluruh observasi tetap digunakan dalam penelitian.

3) Penghapusan Data Duplikat

Pemeriksaan data duplikat dilakukan untuk memastikan setiap observasi hanya muncul satu kali dalam dataset. Hasil pemeriksaan menunjukkan bahwa jumlah data duplikat adalah nol sehingga tidak diperlukan proses penghapusan data.

4) Transformasi Data

Dataset yang digunakan seluruhnya telah berbentuk numerik sehingga tidak diperlukan proses transformasi data menggunakan Label Encoding maupun One-Hot Encoding. Seluruh atribut dapat langsung digunakan pada proses analisis dan pemodelan.

5) Seleksi Fitur

Seleksi fitur dilakukan menggunakan korelasi Pearson untuk mengukur hubungan antara setiap variabel independen dengan variabel target *stress_level*. Berdasarkan hasil analisis korelasi, tiga fitur yaitu *blood_pressure*, *breathing_problem*, dan *living_conditions* memiliki nilai korelasi yang lebih rendah dibandingkan fitur lainnya sehingga dieliminasi dari dataset. Setelah proses seleksi fitur, diperoleh 17 fitur yang digunakan sebagai variabel masukan pada proses klasifikasi.

6) Normalisasi atau Standarisasi Data

Standarisasi dilakukan menggunakan metode *StandardScaler* untuk menyamakan skala antar fitur yang digunakan dalam proses pemodelan. Tahapan ini dilakukan karena beberapa variabel pada dataset memiliki rentang nilai yang berbeda, seperti *anxiety_level*, *depression*, dan *self_esteem*. Dengan melakukan standarisasi, setiap fitur memiliki skala yang lebih seragam sehingga dapat membantu meningkatkan kestabilan proses pembelajaran model, terutama pada algoritma *Naïve Bayes* yang memanfaatkan distribusi probabilitas dari setiap fitur dalam proses klasifikasi.

3. Penanganan Data Tidak Seimbang

Analisis distribusi kelas dilakukan untuk mengetahui kondisi keseimbangan data pada variabel target *stress_level*. Ketidakseimbangan kelas dapat menyebabkan model lebih cenderung memprediksi kelas mayoritas sehingga menurunkan kemampuan model dalam mengenali kelas lainnya.

Berdasarkan hasil analisis, dataset memiliki tiga kategori tingkat stres yaitu rendah, sedang, dan tinggi. Distribusi kelas terdiri dari 373 data untuk kategori rendah, 358 data untuk kategori sedang, dan 369 data untuk kategori tinggi. Persentase masing-masing kelas secara berturut-turut sebesar 33,91%, 32,55%, dan 33,55%. Hasil tersebut menunjukkan bahwa distribusi kelas pada dataset relatif seimbang sehingga tidak diperlukan metode penanganan *imbalanced data* seperti *SMOTE*, *Random Oversampling*, *Random Undersampling*, maupun *class weighting*.

Dengan kondisi distribusi kelas yang seimbang, seluruh data dapat langsung digunakan pada tahap pelatihan model sehingga algoritma *Decision Tree*, *K-Nearest Neighbors* (KNN), dan *Naïve Bayes* dapat mempelajari pola dari setiap kategori tingkat stres secara proporsional.

III. METHODOLOGY

1. *Machine Learning* untuk Klasifikasi


Machine Learning merupakan salah satu cabang dari *Artificial Intelligence* yang memungkinkan sistem untuk mempelajari pola dari data berdasarkan pengalaman tanpa harus diberikan aturan secara eksplisit. Pada penelitian ini digunakan pendekatan *Supervised Learning*, yaitu metode pembelajaran yang memanfaatkan data dengan label target sebagai acuan dalam proses pelatihan model.

Penelitian ini termasuk ke dalam permasalahan klasifikasi karena bertujuan untuk mengelompokkan mahasiswa berdasarkan tingkat stres (*stress_level*) ke dalam beberapa kategori. Model akan mempelajari hubungan antara variabel independen berupa faktor akademik, psikologis, sosial, fisiologis, dan lingkungan terhadap variabel target tingkat stres mahasiswa.

Tahapan penelitian secara umum terdiri dari proses preprocessing data, seleksi fitur menggunakan korelasi Pearson, pembentukan model klasifikasi menggunakan *Decision Tree*, *K-Nearest Neighbors* (KNN), dan *Naïve Bayes*, proses validasi model, serta evaluasi performa berdasarkan beberapa metrik klasifikasi

Alur penelitian secara umum ditunjukkan pada Gambar 4.

Gambar 4. Flowchart Metodologi Penelitian



2. Seleksi Fitur Menggunakan Korelasi Pearson

Seleksi fitur dilakukan untuk menentukan variabel yang memiliki hubungan kuat terhadap target *stress_level*. Metode yang digunakan adalah korelasi Pearson yang mengukur hubungan linear antara variabel independen dan variabel target.

Nilai korelasi Pearson dihitung menggunakan persamaan:

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$

dengan:

- r = nilai korelasi Pearson
- x = variabel independen
- y = variabel target
- $\bar{x}$ = rata-rata variabel x
- $\bar{y}$ = rata-rata variabel y

Nilai korelasi berada pada rentang -1 hingga 1. Nilai mendekati ± 1 menunjukkan hubungan yang kuat, sedangkan nilai mendekati 0 menunjukkan hubungan yang lemah.

Pada penelitian ini digunakan nilai absolut korelasi:

$$|r| \geq 0,6$$

sebagai batas pemilihan fitur. Penggunaan nilai absolut dilakukan agar fitur dengan hubungan negatif tetap dipertahankan karena tetap menunjukkan hubungan kuat terhadap tingkat stres.

Berdasarkan hasil seleksi fitur diperoleh 17 fitur yang digunakan sebagai variabel input model.

3. *Decision Tree*

Decision Tree merupakan algoritma klasifikasi yang membangun struktur keputusan berbentuk pohon berdasarkan karakteristik data. Algoritma ini melakukan pemisahan data secara bertahap berdasarkan fitur yang memberikan pemisahan kelas terbaik.

Pada penelitian ini *Decision Tree* digunakan untuk mempelajari pola hubungan antara faktor-faktor mahasiswa terhadap kategori tingkat stres.

Proses pembentukan node pada *Decision Tree* menggunakan pengukuran impurity. Salah satu metode yang digunakan adalah entropy:

$$Entropy(S) = - \sum_{i=1}^c p_i \log_2(p_i)$$

dengan:

S = kumpulan data

c = jumlah kelas

p_i = probabilitas kelas ke- i

Sedangkan proses pemilihan atribut terbaik dilakukan berdasarkan nilai *Information Gain*:

$$Gain(S, A) = Entropy(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Entropy(S_v)$$

dengan:

$Gain(S, A)$ = nilai peningkatan informasi dari atribut A

S = seluruh data sebelum dilakukan pemisahan

A = atribut yang digunakan untuk melakukan pemisahan

$Values(A)$ = seluruh kemungkinan nilai dari atribut A

S_v = subset data hasil pemisahan berdasarkan nilai v pada atribut A

$|S_v|$ = jumlah data pada subset hasil pemisahan

$|S|$ = jumlah total data sebelum pemisahan

Optimasi parameter *Decision Tree* dilakukan menggunakan *GridSearchCV*.

Tabel 4. Parameter *GridSearchCV* *Decision Tree*

Parameter	Nilai Pengujian
<i>criterion</i>	Gini, entropy
<i>max_depth</i>	None, 5, 10, 15, 20
<i>min_samples_split</i>	2, 5, 10

Parameter tersebut digunakan untuk mencari kombinasi terbaik yang menghasilkan performa klasifikasi optimal.

4. Naïve Bayes

Naïve Bayes merupakan algoritma klasifikasi berbasis probabilitas yang menggunakan Teorema Bayes untuk menghitung kemungkinan suatu data termasuk ke dalam kelas tertentu.

Persamaan dasar *Naïve Bayes*:

$$P(C|X) = \frac{P(X|C)P(C)}{P(X)}$$

dengan:

$P(C|X)$ = probabilitas kelas C berdasarkan data X

$P(X|C)$ = probabilitas data berdasarkan kelas

$P(C)$ = probabilitas awal kelas

$P(X)$ = probabilitas kemunculan data

Pada penelitian ini digunakan algoritma *Gaussian Naïve Bayes* karena fitur yang digunakan berupa data numerik. *Gaussian Naïve Bayes* mengasumsikan bahwa setiap fitur memiliki distribusi normal pada masing-masing kelas.

Probabilitas fitur dihitung menggunakan:

$$P(x_i|C) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$

dengan:

μ = nilai rata-rata fitur pada kelas C

σ = variansi fitur pada kelas C

x_i = nilai fitur ke-i

C = kelas target (*stress_level*)

π = konstanta matematika

Naïve Bayes digunakan sebagai model pembandingan untuk mengetahui kemampuan pendekatan probabilistik dalam melakukan klasifikasi tingkat stres mahasiswa.

Optimasi parameter dilakukan menggunakan GridSearchCV dengan parameter:

Tabel 5. Parameter GridSearchCV Naïve Bayes

Parameter	Nilai Pengujian
var_smoothing	1e-9, 1e-8, 1e-7

5. K-Nearest Neighbors (KNN)

K-Nearest Neighbors merupakan algoritma klasifikasi berbasis jarak yang menentukan kelas suatu data berdasarkan kedekatan dengan sejumlah tetangga terdekat. Perhitungan jarak pada penelitian ini menggunakan *Manhattan Distance*:

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

dengan:

$d(x, y)$ = jarak antara data x dan data y

x_i = nilai fitur ke-i pada data pertama

y_i = nilai fitur ke-i pada data kedua

n = jumlah fitur yang digunakan

Setelah jarak dihitung, algoritma memilih sejumlah k tetangga terdekat. Kelas prediksi ditentukan berdasarkan mayoritas kelas dari tetangga tersebut.

Pada penelitian ini, optimasi parameter KNN dilakukan

menggunakan GridSearchCV dengan parameter:

Tabel 6. Parameter GridSearchCV KNN

Parameter	Nilai Pengujian
n_neighbors	3,5,7,9,11,13,15
weights	uniform, distance
metric	euclidean, manhattan

6. Stratified K-Fold Cross Validation

Evaluasi model dilakukan menggunakan *Stratified K-Fold Cross Validation* untuk memperoleh hasil pengujian yang lebih stabil. Metode ini membagi dataset menjadi beberapa bagian (*fold*) dengan tetap mempertahankan proporsi setiap kelas pada masing-masing *fold*.

Pada penelitian ini digunakan:

$$K = 5$$

Dataset dibagi menjadi lima *fold*, dimana setiap iterasi menggunakan empat *fold* sebagai data pelatihan dan satu *fold* sebagai data pengujian.

Penggunaan *Stratified K-Fold* dipilih karena dataset memiliki tiga kategori tingkat stres sehingga distribusi kelas tetap terjaga selama proses validasi.

7. Hyperparameter Tuning Menggunakan GridSearchCV

Hyperparameter tuning dilakukan untuk mendapatkan konfigurasi model terbaik. Metode yang digunakan adalah GridSearchCV yang melakukan pencarian kombinasi parameter secara sistematis.

Tahapan GridSearchCV:

1. Menentukan parameter yang akan diuji.
2. Membentuk seluruh kombinasi parameter.
3. Melakukan validasi silang pada setiap kombinasi.
4. Memilih kombinasi dengan nilai evaluasi terbaik.

Pada penelitian ini, fungsi evaluasi yang digunakan pada GridSearchCV adalah **F1-Macro**. Penggunaan F1-Macro juga digunakan sebagai dasar utama dalam membandingkan performa akhir ketiga algoritma.

Nilai F1-Macro dihitung dengan:

$$F1_{macro} = \frac{1}{N} \sum_{i=1}^N F1_i$$

dengan:

$F1_{macro}$ = rata-rata nilai F1 dari seluruh kelas

N = jumlah kelas

$F1_i$ = nilai F1 pada kelas ke-i

8. Metrik Evaluasi

Evaluasi performa model dilakukan menggunakan beberapa metrik klasifikasi yaitu *accuracy*, *precision*, *recall*, dan *F1-score*.

a) Accuracy

Accuracy digunakan untuk mengetahui persentase prediksi benar dari seluruh data.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

b) Precision

Precision menunjukkan tingkat ketepatan model ketika memberikan prediksi suatu kelas.

$$Precision = \frac{TP}{TP + FP}$$

c) *Recall*

Recall menunjukkan kemampuan model dalam mengenali data yang benar pada suatu kelas.

$$Recall = \frac{TP}{TP + FN}$$

d) *F1-Score*

F1-score digunakan untuk melihat keseimbangan antara *precision* dan *recall*.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Penggunaan beberapa metrik evaluasi dilakukan agar performa model dapat dianalisis secara lebih menyeluruh.

9. *Confusion Matrix*

Confusion Matrix digunakan untuk menganalisis pola kesalahan klasifikasi yang dilakukan oleh model.

Matriks ini menunjukkan perbandingan antara label aktual dan hasil prediksi model yang terdiri dari:

- *True Positive (TP)* : data yang diprediksi sesuai dengan kelas sebenarnya
- *True Negative (TN)*: data bukan kelas tertentu yang berhasil dikenali
- *False Positive (FP)*: data kelas lain yang salah diprediksi sebagai kelas tertentu
- *False Negative (FN)*: data suatu kelas yang gagal dikenali oleh model

Analisis confusion matrix membantu mengetahui kelas mana yang paling sering mengalami kesalahan prediksi.

10. *Confidence Prediction*

Confidence prediction digunakan untuk mengetahui tingkat keyakinan model terhadap hasil prediksi yang diberikan. Nilai confidence diperoleh dari probabilitas prediksi kelas yang dihasilkan oleh model menggunakan fungsi:

$$Confidence = \max (P(C|x))$$

Keterangan:

Confidence = tingkat keyakinan model terhadap prediksi

$P(C|X)$ = probabilitas suatu data X termasuk ke dalam kelas C

max = memilih probabilitas kelas terbesar

Pada penelitian ini, *confidence prediction* digunakan untuk membandingkan tingkat keyakinan prediksi dari algoritma *Decision Tree*, *Naïve Bayes*, dan KNN. Nilai confidence yang tinggi menunjukkan bahwa model memiliki keyakinan lebih besar terhadap hasil klasifikasi, sedangkan *confidence* yang rendah menunjukkan adanya ketidakpastian model dalam menentukan kelas.

IV. RESULT AND DISCUSSION

1. Evaluasi Model

Evaluasi model dilakukan menggunakan parameter terbaik yang diperoleh dari proses GridSearchCV dengan *Stratified K-Fold Cross Validation* sebanyak 5-fold. Parameter terbaik tersebut kemudian digunakan

untuk mengukur performa masing-masing algoritma berdasarkan nilai F1-Macro.

Berdasarkan hasil optimasi, algoritma *Naïve Bayes* memperoleh parameter terbaik dengan nilai *var_smoothing* = **1e-09** dan menghasilkan nilai *F1-Macro* sebesar **88,47%**. Pada algoritma *Decision Tree*, kombinasi parameter terbaik yang diperoleh yaitu *criterion* = *entropy*, *max_depth* = *None*, dan *min_samples_split* = 2 dengan nilai *F1-Macro* sebesar **87,72%**. Sementara itu, algoritma KNN memperoleh parameter terbaik yaitu *metric* = *manhattan*, *n_neighbors* = 7, dan *weights* = *distance* dengan nilai *F1-Macro* sebesar **86,73%**.

Hasil tersebut menunjukkan bahwa ketiga algoritma memiliki performa yang relatif seimbang dalam melakukan klasifikasi tingkat stres mahasiswa. Berdasarkan hasil evaluasi menggunakan nilai *F1-Macro*, algoritma *Naïve Bayes* memperoleh nilai *F1-Macro* tertinggi dibandingkan *Decision Tree* dan *K-Nearest Neighbors* (KNN) pada dataset yang digunakan dalam penelitian ini.

2. Tabel Perbandingan Model

Tabel 7. Perbandingan Performa Model

Model	Parameter Terbaik	Accuracy	Precision	Recall	F1-Score
Naive Bayes	var_smoothing = 1e-09	0.88	0.90	0.88	0.88
Decision Tree	entropy, None, 2	0.88	0.88	0.88	0.88
KNN	Manhattan, k=7, distance	0.87	0.87	0.87	0.87

Berdasarkan tabel tersebut, *Naïve Bayes* memperoleh nilai F1-Score tertinggi sebesar 88,47%, diikuti oleh *Decision Tree* sebesar 87,72%, dan *K-Nearest Neighbors* (KNN) sebesar 86,73%. Perbedaan nilai F1-Score antar algoritma relatif kecil, yang menunjukkan bahwa ketiga algoritma memiliki kemampuan klasifikasi yang kompetitif pada dataset yang digunakan.

Naïve Bayes memperoleh nilai *F1-Score* tertinggi pada penelitian ini. Hal tersebut menunjukkan bahwa pada dataset yang digunakan, pendekatan probabilistik pada *Naïve Bayes* mampu menghasilkan klasifikasi tingkat stres dengan performa yang lebih tinggi dibandingkan algoritma lain berdasarkan metrik *F1-Score*. Sementara itu, *Decision Tree* menghasilkan performa yang mendekati *Naïve Bayes* dengan membentuk aturan keputusan berdasarkan karakteristik fitur pada data. KNN memiliki performa sedikit lebih rendah karena proses klasifikasinya bergantung pada tingkat kedekatan antar data.




3. Analisis *Confusion Matrix*

Berdasarkan hasil *confusion matrix*, model *Naïve Bayes* menunjukkan kemampuan klasifikasi yang cukup baik pada tiga kategori tingkat stres, yaitu rendah, sedang, dan tinggi. Pada kelas Rendah, model memperoleh *precision* sebesar 0,93 dan *recall* sebesar 0,83, yang menunjukkan bahwa sebagian besar data pada kelas tersebut berhasil dikenali oleh model, meskipun masih terdapat beberapa data yang salah diklasifikasikan.

Pada kelas Sedang, *Naïve Bayes* memperoleh *recall* sebesar 0,84, yang menunjukkan bahwa model mampu mengenali sebagian besar data dengan kategori tingkat stres sedang. Sementara itu, pada kelas Tinggi, model memperoleh *recall* sebesar 0,97, sehingga sebagian besar data pada kategori tersebut berhasil diklasifikasikan dengan benar.

Pada algoritma *Decision Tree*, hasil *confusion matrix* menunjukkan performa klasifikasi yang relatif seimbang pada ketiga kategori stres. Nilai *precision*, *recall*, dan *F1-score* berada pada rentang sekitar 0,85–0,89, yang menunjukkan bahwa model mampu mengenali pola antar kelas dengan distribusi kesalahan yang relatif merata.

Sementara itu, algoritma *K-Nearest Neighbors* (KNN) menghasilkan nilai *recall* tertinggi pada kelas Sedang sebesar 0,89, tetapi memiliki nilai *precision* yang lebih rendah pada kelas tersebut yaitu sebesar 0,86. Hal ini menunjukkan bahwa model mampu mengenali sebagian besar data pada kelas Sedang, namun terdapat beberapa data dari kelas lain yang diprediksi sebagai kelas tersebut.

Gambar 5. *Confusion Matrix Naïve Bayes*Gambar 6. *Confusion Matrix Decision Tree*Gambar 7. *Confusion Matrix K-Nearest Neighbors*

4. Analisis *Confidence Prediction*

Analisis *confidence prediction* dilakukan untuk mengetahui tingkat keyakinan model terhadap hasil prediksi yang diberikan.

Tabel 8. Perbandingan *Confidence Prediction*

Model	<i>Confidence</i> Prediksi Benar	<i>Confidence</i> Prediksi Salah
Naïve Bayes	99.72%	97.71%
Decision Tree	99.58%	94.32%
KNN	98.04%	66.89%

Berdasarkan hasil tersebut, *Naïve Bayes* menunjukkan nilai *confidence* yang tinggi baik pada prediksi benar maupun prediksi salah. Perbedaan nilai *confidence* antara kedua kondisi relatif kecil, yang menunjukkan bahwa model memberikan tingkat keyakinan yang tinggi terhadap hasil prediksinya.

Decision Tree menghasilkan *confidence* sebesar 99,58% pada prediksi benar dan 94,32% pada prediksi salah. Hal ini menunjukkan bahwa model memberikan tingkat keyakinan yang tinggi terhadap hasil klasifikasi yang dilakukan, meskipun tingkat *confidence* yang tinggi tidak selalu menjamin prediksi yang benar.

Sementara itu, KNN menghasilkan perbedaan *confidence* yang lebih besar antara prediksi benar dan salah. *Confidence* prediksi benar sebesar 98,04%, sedangkan *confidence* prediksi salah sebesar 66,89%. Hal ini menunjukkan bahwa KNN memberikan tingkat keyakinan yang lebih rendah ketika menghasilkan prediksi yang salah dibandingkan dua algoritma lainnya.

5. *Error Analysis*

Analisis kesalahan dilakukan untuk mengidentifikasi pola kesalahan klasifikasi yang terjadi pada masing-masing algoritma berdasarkan hasil prediksi model. Analisis ini bertujuan untuk memahami kondisi ketika model mengalami kesulitan dalam membedakan kategori tingkat stres berdasarkan fitur yang digunakan.

Pada *Naïve Bayes*, meskipun memperoleh nilai *F1-Macro* tertinggi, masih terdapat beberapa kesalahan klasifikasi antar kategori tingkat stres. Hal ini menunjukkan bahwa beberapa data memiliki karakteristik fitur yang serupa antar kelas sehingga menyebabkan model menghasilkan prediksi yang kurang tepat.

Pada *Decision Tree*, kesalahan prediksi masih terjadi pada beberapa data meskipun model mampu menghasilkan performa yang kompetitif. Hal tersebut menunjukkan bahwa pola tertentu pada data belum sepenuhnya dapat dipisahkan berdasarkan aturan keputusan yang terbentuk oleh model.

Sementara itu, pada *K-Nearest Neighbors* (KNN), kesalahan klasifikasi terlihat dari adanya perbedaan *confidence* yang lebih rendah pada prediksi salah dibandingkan prediksi benar. Secara keseluruhan, kesalahan pada ketiga algoritma menunjukkan bahwa beberapa data memiliki pola yang berdekatan antar kategori stres sehingga masih sulit dibedakan oleh model berdasarkan fitur yang tersedia.

6. Interpretasi Hasil


Berdasarkan hasil eksperimen, ketiga algoritma mampu melakukan klasifikasi tingkat stres mahasiswa dengan performa yang kompetitif. Berdasarkan nilai *F1-Macro* menunjukkan bahwa *Naïve Bayes* memperoleh nilai tertinggi yaitu **88,47%**, kemudian *Decision Tree* sebesar **87,72%**, dan KNN sebesar **86,73%** pada dataset yang digunakan dalam penelitian ini.

Hasil tersebut menjawab *Research Question* mengenai perbandingan performa algoritma klasifikasi tingkat stres mahasiswa. Perbedaan nilai *F1-Macro* yang relatif kecil menunjukkan bahwa ketiga algoritma mampu mempelajari pola pada dataset, meskipun terdapat perbedaan kemampuan dalam mengenali kategori tingkat stres.


Berdasarkan hasil evaluasi, *Naïve Bayes* memperoleh nilai *F1-Macro* tertinggi sehingga menunjukkan performa klasifikasi yang lebih tinggi dibandingkan algoritma lainnya dalam skenario penelitian ini. Selain itu, hasil *confidence prediction* menunjukkan tingkat keyakinan model terhadap hasil prediksi yang dihasilkan. Sementara itu, *Decision Tree* memiliki keunggulan dalam hal interpretasi karena menghasilkan aturan keputusan yang lebih mudah dipahami.

Selain evaluasi performa, analisis tambahan dilakukan menggunakan *feature importance* pada algoritma *Decision Tree* untuk mengetahui fitur yang paling berkontribusi dalam proses klasifikasi. Hasil visualisasi *Decision Tree* menunjukkan aturan keputusan yang terbentuk berdasarkan fitur hasil seleksi. *Feature importance* memberikan gambaran mengenai atribut yang paling sering digunakan model dalam membedakan kategori tingkat stres, namun tidak menunjukkan hubungan sebab-akibat terhadap tingkat stres.

Gambar 8. *Feature Importance Decision Tree*



Gambar 9. Visualisasi Model *Decision Tree*



V. CONCLUSION

Berdasarkan hasil penelitian, algoritma *Decision Tree*, *Naïve Bayes*, dan *K-Nearest Neighbors* (KNN) dapat digunakan untuk melakukan klasifikasi tingkat stres mahasiswa pada dataset *Student Stress Factors: A Comprehensive Analysis*. Proses evaluasi menggunakan *Stratified K-Fold Cross Validation* dan optimasi parameter menggunakan *GridSearchCV* menunjukkan bahwa ketiga algoritma memiliki performa yang kompetitif dalam melakukan klasifikasi.

Hasil eksperimen menunjukkan bahwa *Naïve Bayes* memperoleh nilai *F1-Macro* tertinggi sebesar **88,47%**, diikuti oleh *Decision Tree* sebesar **87,72%**, dan KNN sebesar **86,73%**. Hasil tersebut menunjukkan bahwa pada dataset yang digunakan dalam penelitian ini, *Naïve Bayes* memiliki kemampuan klasifikasi yang lebih tinggi berdasarkan nilai *F1-Macro* dibandingkan algoritma lainnya.

Untuk penelitian selanjutnya, dapat dilakukan pengembangan menggunakan dataset dengan jumlah data yang lebih besar, metode seleksi fitur yang berbeda, atau algoritma klasifikasi lain untuk mengevaluasi dan meningkatkan performa klasifikasi tingkat stres mahasiswa.

REFERENCES

- [1] World Health Organization, "Mental health: strengthening our response," World Health Organization. [Online]. Available: <https://www.who.int/news-room/fact-sheets/detail/mental-health-strengthening-our-response?>
- [2] A. Al Rivaldi, "Analisis Faktor Penyebab Stres pada Mahasiswa dan Dampaknya terhadap Kesehatan Mental," *Detect. J. Inov. Ris. Ilmu Kesehat.*, vol. 2, no. 4, pp. 11–18, 2024, doi: <https://doi.org/10.55606/detect.v2i4.4378>.
- [3] A. Muna, T. D. Santi, and P. Ariscasari, "Faktor-Faktor yang Mempengaruhi Kejadian Stres pada Mahasiswa yang sedang Menyusun Skripsi," *Intan Husada J. Ilm. Keperawatan*, vol. 5, no. 1, pp. 413–422, 2025, doi: <https://doi.org/10.54082/jupin.1217>.
- [4] rxnach, "Student Stress Factors: A Comprehensive Analysis," Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/rxnach/student-stress-factors-a-comprehensive-analysis>
- [5] P. Schöber, C. Boer, and L. A. Schwarte, "Correlation Coefficients: Appropriate Use and Interpretation," vol. 126, no. 5, pp. 1763–1768, 2018, doi: [10.1213/ANE.00000000000002864](https://doi.org/10.1213/ANE.00000000000002864).